

O que realmente move o preço da comida no Brasil?

Clima, safra, macroeconomia e custo de frete na inflação alimentar regional.

A pergunta e o grão da tabela

- **Alvo:** IPCA do grupo *Alimentação e bebidas*, variação mensal por área urbana
- **Explicativas:** clima local, seca, estimativa de safra, macro nacional, preço de combustível
- **Denominador comum:** só duas coisas são compartilhadas por todas as fontes — `sigla_uf` e o mês
- **Grão final:** UF × mês, formato largo, chave única (`sigla_uf`, `ano_mes`)

Cada fonte chega num grão diferente — estação meteorológica, produto agrícola, item de IPCA, país inteiro. Tudo teve de ser reduzido a UF × mês antes de qualquer merge, e `data/raw/` nunca é modificado.

As seis fontes

IBGE / SIDRA — IPCA

O alvo: inflação de alimentos. Mês × área urbana × item, 2006-07 → 2026-07.

IBGE / LSPA + PAM

Estimativa de safra e sua revisão mensal. UF × produto × mês, 11 produtos.

INMET / BDMEP

Chuva, temperatura, extremos. Estação × dia, 1,27 GB, 701 estações.

BCB / SGS

Dólar, Selic, IPCA cheio, IGP-M. Brasil × mês, zero nulos.

ANA — Monitor de Secas

Severidade e área em seca. Já em UF × mês, via API REST aberta.

ANP — Preços

Diesel, gasolina, etanol, GLP. UF × mês × produto, 26.446 linhas.

O sinal do IPCA estava invertido

```
# ERRADO – apaga o menos de todo valor negativo  
df['valor'].astype(str).str.replace('...', '').str.replace('-', '')
```

32.696

antes: 0

valores negativos em 83.383 linhas
— toda a deflação da série

0,75 %

antes: 3,14 %

média mensal do índice (≈ 45 % a.a.
com o bug)

−56,62 %

antes: 0,00

mínimo da série; no grupo
Alimentação a média caiu a 0,59 %/
mês

O - é o marcador do SIDRA para “não publicado”. Sem bruto intacto em data/raw/, a correção custou a re-coleta das 168 requisições — e virou teste permanente no código.

Três merges que falhariam em silêncio

1 · Devolve tudo vazio

```
esquerda  "2015-01"  
direita   "2015-01-01"  
→ 0 de 3.726 casaram
```

São duas strings, o pandas aceita: uma tabela inteira de vazio disfarçada de junção.

2 · Multiplica a espinha

```
3.726 → 40.986 linhas  
match 79,6 %  
→ parece saudável
```

A safra tem 40.770 duplicatas na chave — uma por produto. Em combustíveis o fator é 5.

3 · Inventa a variação

```
2018-02    4,05  
2018-07    4,30  
→ “+6,86 % no mês”
```

São quatro meses. Não é erro de cálculo, é erro de rótulo — e nenhum `checa_join` o detecta.

O contrato que fecha as três portas

FUNÇÃO

O QUE GARANTE

`padroniza_chaves(df)`

`sigla_uf` → duas maiúsculas; `ano_mes` → `Period[M]`

`valida_chaves(df)`

recusa sigla fora do padrão, tipo errado e chave duplicada

`checa_join(antes, depois)`

levanta erro se o nº de linhas mudou ou se o match foi 0 %

`Period[M]` é o único tipo sem dia — não existe um 2015-01-01 para divergir de um 2015-01. E toda variação é calculada sobre a grade completa de meses, antes do merge: o mês ausente vira NaN e a variação nasce NaN junto.

A espinha é o calendário



Cinco LEFT JOINS sobre a grade de 27 UF × 138 meses, com `checa_join()` depois de cada um. As 3.726 linhas se mantêm nos cinco merges — nenhum fan-out; um único filtro no fim leva a 2.088. Depois o T-025 pendura a ANP nessa espinha: 2.088 → 2.088 linhas, 89 → 108 colunas.

2.088 linhas × 108 colunas

colunas por família



Chave única (`sigla_uf`, `ano_mes`) em `Period[M]` · 16 UFs × 138 meses, 2015-01 → 2026-06 · zero duplicatas · 1,8 MB. Dicionário de variáveis cobrindo 100 % das colunas, com o que cada vazio significa.

Cada vazio afirma uma coisa diferente

FAMÍLIA	NULOS	O QUE O NAN SIGNIFICA
seca_*	34–38 %	a UF não era monitorada pela ANA naquele mês
comb_preco_*	~23 %	mês sem pesquisa — 33 dos 138 meses da janela
comb_var12_*	~39 %	precisa do mês e do mesmo mês do ano anterior
safra_revisao_pct_*	9–53 %	revisão indefinida: é janeiro, ou a UF não planta

Estrutural primeiro, histórica depois

Assertivas que falham a execução

- chave única · 2.088 linhas · 16 UFs · 138 meses
- ano_mes é Period[M] em toda a tabela
- o alvo tem deflação — o bug do sinal não voltou
- nenhuma coluna > 40 % nula sem justificativa escrita
- preço de líquido em 1–15 R\$/l · GLP em 20–200 R\$


A tabela reconhece o que aconteceu

- seca do Ceará em 2017-01: severidade 4,52, S4plus 63,64 %
- pico da inflação de alimentos em 2020-11: 18,1 % em 12 meses
- choque do diesel: +62,1 % em 2022-07, -33,8 % em 2023-07
- sazonalidade: chuva mediana de 226 mm em janeiro contra 13 mm em agosto

Ninguém disse à tabela que esses eventos existiram — ela os reconhece sozinha. É o que separa uma junção que roda de uma junção correta.

A dimensão que o macro não tem

comb_diesel_vs_br_pct



O Acre paga 20 % a mais pelo diesel que a mediana do país, todo mês da série — distância de refinaria e custo de escoamento. `macro_dolar_ptax_medio` é idêntica nas 16 UFs e não explica isso. E no tempo: a correlação do diesel com o alvo vai de **0,422 sem defasagem a 0,487 com o diesel adiantado 4 meses**, caindo depois — a forma de um repasse de custo.